

I) Introduction

Le cours d'ITC présente de manière assez rapide plusieurs concepts d'apprentissages et de jeux. Les détails des algorithmes ne sont pas au programme.

II) Apprentissage

II.1) Apprentissage supervisé

II.1.a) K plus proches voisins

Définition 1 [Jeu de données]

On appelle *jeu de données étiquetés* un ensemble d'objets, associés à des *classes*. En général, les objets sont ramenés à des éléments de $\mathbb{R}^n$, et les classes à des entiers de $\llbracket 0, C - 1 \rrbracket$.

Définition 2 [Apprentissage supervisé]

Un algorithme d'*apprentissage supervisé* prend en entrée un jeu de données, et l'utilise pour classer de nouveaux objets inconnus.

Première idée : On a des points de $\mathbb{R}^n$ rangés dans des classes (=des catégories). On veut ranger un nouveau point de $\mathbb{R}^n$ dans ces classes. On peut simplement regarder la classe de l'objet le plus proche (ou des K objets les plus proches) et classer notre objet en conséquence !

C'est l'algorithme des K plus proches voisins (aussi appelés k-NN).

<http://vision.stanford.edu/teaching/cs231n-demos/knn/>

II.1.b) Test et validation

Si on utilise tous nos exemples pour l'algorithme, comment évaluer ses performances ? On ne peut pas le tester sur un objet qu'on lui a fourni à l'entraînement, ce serait de la triche !

Définition 3 [données de validation]

Lorsqu'on a un jeu de données, on va garder (aléatoirement) un certain pourcentage d'entre elles, en général réparti uniformément entre les classes, pour la validation. Souvent, ce pourcentage est au alentours de 1-10%, mais cela va beaucoup varier en fonction des données.

On va ensuite tester notre algorithme sur ce jeu de données de validation, et mesurer les erreurs.

Définition 4 [matrice de confusion]

On peut ensuite écrire la *matrice de confusion* associée : il s'agit d'un tableau où, pour chaque classe, on indique le pourcentage d'objet de cette classe qui ont été placés dans chaque classe par l'algorithme.

	A	B
A	95%	5%
B	1%	99%

Ce tableau indique que, parmi les objets réellement de classe A, 95% ont été bien classifiés et 5% mal classifiés.

II.2) Apprentissage non supervisé

On a maintenant un problème différent : on dispose toujours d'un jeu de données, mais cette fois il n'est pas *étiqueté*, c'est à dire qu'on ne connaît pas la classification des objets.

On aimerait automatiquement déduire une classification des objets en C classes, en fonction de leur complexité.

Plus précisément, on cherche à minimiser la quantité $\sum_{S \text{ une classe}} \sum_{x \in S} \|x - \mu_S\|_2$ où $\mu_S = \frac{1}{|S|} \sum_{x \in S} x$ le barycentre de la classe S .

Pour cela, on va utiliser une méthode *itérative*.

<https://hckr.pl/k-means-visualization/>

ALGORITHME DES K-MOYENNES

```

1 Entrées :
2   └─ un ensemble de données D (des vecteurs de flottants)
3   └─ un entier C le nombre de classes
4 Sortie : une association de D à  $\llbracket 1, C \rrbracket$ 
5 Placer  $u_1, \dots, u_C$  des centres. (On peut tirer les positions aléatoirement, ou bien utiliser des
   méthodes pour les répartir équitablement dans D)
6 Tant que on n'a pas convergé en général, on s'arrête quand l'attribution ne change plus
7   └─ Pour  $i$  de 1 à C
8     └─  $S_i \leftarrow$  l'ensemble des points pour lesquels  $u_i$  est le centre le plus proche.
9     └─ Pour  $i$  de 1 à C
10      └─  $u_i \leftarrow$  le barycentre de  $S_i$ 
11 Renvoyer  $u_1, \dots, u_n$ 

```

La preuve n'est pas au programme, mais l'algorithme de k-moyennes converge toujours. En revanche, il peut converger vers un minimum *local* de la fonction de coût, ce qui peut donner des résultats absurdes.

Le placement de départ des points a une influence importante sur la qualité de la solution obtenue.

III) Modélisation des jeux

On va, durant toute cette partie, utiliser l'exemple du jeu de **Chomp**.



C'est un jeu à deux joueurs, qui se joue avec une tablette de chocolat. Le carré en haut à droite est empoisonné, et donc, le/la joueur.euse qui la mange a perdu.

Chacun leur tours, les joueurs doivent manger un rectangle de carrés en bas à droite de la tablette.

Définition 5 [jeu de Chomp]

On prend un rectangle (la tablette de chocolat) de taille $n \times m$.

Le carré en position 1×1 est empoisonné.

Chacun leur tours, les joueurs choisissent une case non mangée $i \times j$ et mangent tous les carrés situés dans le rectangle en bas à droite de cette case (la case incluse).

Un joueur perd si il est obligé de manger la case 1×1 , et, dans ce cas, l'autre joueur gagne.

III.1) Graphe d'accessibilité