

Languages et expressions régulières

Ambre Le Berre

2025/2026

MP option info

Agenda

1. Vocabulaire
2. Expression régulière, langages réguliers

Vocabulaire

Alphabet et mots

- Un **alphabet** est un ensemble Σ de **lettres**. Par exemple, $\Sigma = \{a, b\}$ est un alphabet.
-
-
-
-

Alphabet et mots

- Un **alphabet** est un ensemble Σ de **lettres**. Par exemple, $\Sigma = \{a, b\}$ est un alphabet.
- Un **mot** sur un alphabet est une suite finie de lettres de cet alphabet. Par exemple, *abba* est un mot sur Σ .
-
-
-

Alphabet et mots

- Un **alphabet** est un ensemble Σ de **lettres**. Par exemple, $\Sigma = \{a, b\}$ est un alphabet.
- Un **mot** sur un alphabet est une suite finie de lettres de cet alphabet. Par exemple, *abba* est un mot sur Σ .
- On note ε le mot vide, qui ne contient aucune lettre.
-
-

Alphabet et mots

- Un **alphabet** est un ensemble Σ de **lettres**. Par exemple, $\Sigma = \{a, b\}$ est un alphabet.
- Un **mot** sur un alphabet est une suite finie de lettres de cet alphabet. Par exemple, *abba* est un mot sur Σ .
- On note ε le mot vide, qui ne contient aucune lettre.
- Pour deux mots u et v , on note uv leur concaténation.
- On note $|u| \in \mathbb{N}$ la longueur d'un mot.

Vocabulaires sur les mots

Soit $m = m_1 m_2 \dots m_n \in \Sigma^*$ un mot.

- un **préfixe** de m est un mot $m_1 \dots m_i$ avec $0 \leq i \leq n$.

-

-

-

-

Vocabulaires sur les mots

Soit $m = m_1 m_2 \dots m_n \in \Sigma^*$ un mot.

- un **préfixe** de m est un mot $m_1 \dots m_i$ avec $0 \leq i \leq n$.
- un **suffixe** de m est un mot $m_{i+1} \dots m_n$ avec $0 \leq i \leq n$.
-
-
-

Vocabulaires sur les mots

Soit $m = m_1 m_2 \dots m_n \in \Sigma^*$ un mot.

- un **préfixe** de m est un mot $m_1 \dots m_i$ avec $0 \leq i \leq n$.
- un **suffixe** de m est un mot $m_{i+1} \dots m_n$ avec $0 \leq i \leq n$.
- un **facteur** de m est un mot $m_i \dots m_j$ avec $0 \leq i, j \leq n$.
-
-

Vocabulaires sur les mots

Soit $m = m_1 m_2 \dots m_n \in \Sigma^*$ un mot.

- un **préfixe** de m est un mot $m_1 \dots m_i$ avec $0 \leq i \leq n$.
- un **suffixe** de m est un mot $m_{i+1} \dots m_n$ avec $0 \leq i \leq n$.
- un **facteur** de m est un mot $m_i \dots m_j$ avec $0 \leq i, j \leq n$.
- un **sous-mot** de m est un mot $m_{i_1} m_{i_2} \dots m_{i_k}$ avec $i_1 < i_2 < \dots < i_k \in \llbracket 1, n \rrbracket$
-

Vocabulaires sur les mots

Soit $m = m_1 m_2 \dots m_n \in \Sigma^*$ un mot.

- un **préfixe** de m est un mot $m_1 \dots m_i$ avec $0 \leq i \leq n$.
- un **suffixe** de m est un mot $m_{i+1} \dots m_n$ avec $0 \leq i \leq n$.
- un **facteur** de m est un mot $m_i \dots m_j$ avec $0 \leq i, j \leq n$.
- un **sous-mot** de m est un mot $m_{i_1} m_{i_2} \dots m_{i_k}$ avec $i_1 < i_2 < \dots < i_k \in \llbracket 1, n \rrbracket$
- ε est préfixe, suffixe, facteur et sous-mot de n'importe quel mot.

Languages

- Un **language** est un ensemble $L \subseteq \Sigma^*$ de mots sur un alphabet
-

Languages

- Un **language** est un ensemble $L \subseteq \Sigma^*$ de mots sur un alphabet
- On note $\emptyset$ le language vide (à ne pas confondre avec $\{\epsilon\}$)

Expression régulière, langages réguliers

Opérations régulières sur les languages

On définit plusieurs opérations dites régulières sur les languages. Soit L_1, L_2 deux languages sur un alphabet Σ .

- $L_1 \cup L_2 = \{u \mid u \in L_1 \text{ ou } u \in L_2\}$ est l'union des languages.

-

-

-

Opérations régulières sur les langages

On définit plusieurs opérations dites régulières sur les langages. Soit L_1, L_2 deux langages sur un alphabet Σ .

- $L_1 \cup L_2 = \{u \mid u \in L_1 \text{ ou } u \in L_2\}$ est l'union des langages.
- $L_1 L_2 = \{uv \mid u \in L_1, v \in L_2\}$ est la concaténation des langages.

•

•

Opérations régulières sur les langages

On définit plusieurs **opérations** dites **régulières** sur les langages. Soit L_1, L_2 deux langages sur un alphabet Σ .

- $L_1 \cup L_2 = \{u \mid u \in L_1 \text{ ou } u \in L_2\}$ est l'**union** des langages.
- $L_1 L_2 = \{uv \mid u \in L_1, v \in L_2\}$ est la **concaténation** des langages.
- $L_1^* = \{u_1 u_2 \dots u_n \mid n \in \mathbb{N}, u_1 \dots u_n \in L_1\}$ l'**étoile de Kleene** d'un langage (ou juste **étoile**).
-

Opérations régulières sur les langages

On définit plusieurs opérations dites régulières sur les langages. Soit L_1, L_2 deux langages sur un alphabet Σ .

- $L_1 \cup L_2 = \{u \mid u \in L_1 \text{ ou } u \in L_2\}$ est l'union des langages.
- $L_1 L_2 = \{uv \mid u \in L_1, v \in L_2\}$ est la concaténation des langages.
- $L_1^* = \{u_1 u_2 \dots u_n \mid n \in \mathbb{N}, u_1 \dots u_n \in L_1\}$ l'étoile de Kleene d'un langage (ou juste étoile).
- L'intersection et la soustraction ensembliste ne sont pas des opérations régulières !

Expressions régulières

On utilise **expressions régulières** pour définir une partie des languages.

Définition inductive

- Cas de bases :
 - ε est une expression régulière représentant le language $\{\varepsilon\}$
 - si $a \in \Sigma$, a est une expression régulière représentant le language $\{a\}$.
-

Expressions régulières

On utilise **expressions régulières** pour définir une partie des langages.

Définition inductive

- Cas de bases :
 - ε est une expression régulière représentant le langage $\{\varepsilon\}$
 - si $a \in \Sigma$, a est une expression régulière représentant le langage $\{a\}$.
- Cas inductifs : si e_1, e_2 sont des expressions régulières qui représentent des langages L_1 et L_2 , alors
 - e_1^* représente le langage L_1^*
 - $e_1 \mid e_2$ représente le langage $L_1 \cup L_2$
 - $e_1 e_2$ représente le langage $L_1 L_2$

Expressions régulières : raccourcis

On utilise souvent les syntaxes suivantes par facilité :

- e^+ pour désigner ee^*
- e^n pour désigner $eee...e$ (n fois)
- $e?$ pour désigner $e \mid \varepsilon$

Quelques exemples

Décrivez, en quelques mots, les langages décrits par les expressions régulières suivantes sur l'alphabet $\Sigma = \{a, b\}$:

- $(a|b)^*$
- $(a|b)^+$
- $(b^*ab^*)^5$
- $(ab \mid b)^*$

Dans l'autre sens

Donnez des expressions régulières pour les langages suivants :

- les mots qui contiennent “abba”
- les mots qui contiennent d'abord que des b (au moins 1), puis que des a (au moins 1)
- les mots dont la longueur est multiple de 3
- les mots dont “abba” est un sous-mot

Language régulier / rationnel

Un langage **régulier** ou **rationnel** est un langage qui peut être représenté par une expression régulière.

Q : Est ce que tous les langages sont réguliers ?

Language régulier / rationnel

Un langage **régulier** ou **rationnel** est un langage qui peut être représenté par une expression régulière.

Q : Est ce que tous les langages sont réguliers ? Non !

Un exemple de langage non régulier

Le langage $L_0 = \{a^n b^n \mid n \in \mathbb{N}\}$ n'est pas régulier.

Un exemple de langage non régulier

Le langage $L_0 = \{a^n b^n \mid n \in \mathbb{N}\}$ n'est pas régulier.

Intuition : les expressions régulières ont toujours une “mémoire” finie. Entre autre, elle ne peuvent pas “compter” n “a” pour attendre ensuite le même nombre de “b”.

Lemme de l'étoile (première version)

Soit L un langage régulier. Alors il existe N , tel que pour tout mot $u \in L$ avec $|u| \geq N$, il existe une décomposition $u = xyz$, telle que :

- $|xy| \leq N$
- $y \neq \varepsilon$
- $xy^*z \subseteq L$

Montrer qu'un langage n'est pas rationnel

Montrons que L_0 n'est pas rationnel par l'absurde : si L_0 est rationnel, alors, soit $N \in \mathbb{N}$ suffisamment grand pour appliquer le lemme de l'étoile.

On prend le mot $u = a^{N+1}b^{N+1} \in L_0$. Supposons qu'il existe $xyz = u$ tel que

$$|xy| \leq N, y \neq \varepsilon \text{ et } xy^*z \subseteq L$$

Montrer qu'un langage n'est pas rationnel

Montrons que L_0 n'est pas rationnel par l'absurde : si L_0 est rationnel, alors, soit $N \in \mathbb{N}$ suffisamment grand pour appliquer le lemme de l'étoile.

On prend le mot $u = a^{N+1}b^{N+1} \in L_0$. Supposons qu'il existe $xyz = u$ tel que

$$|xy| \leq N, y \neq \varepsilon \text{ et } xy^*z \subseteq L$$

Alors, comme $|xy| \leq N$, x et y sont de la forme a^p et a^k , et z est de la forme $a^l b^{p+k+l}$.

Donc, $a^p(a^k)^*a^l b^{p+k+l} \subseteq L_0$. Entre autre, $a^{p+2k+l}b^{p+k+l} \in L_0$. Absurde !

Exercice

Montrer que le langage $L_p = \{u_1 u_2 \dots u_k \mid u_1 u_2 \dots u_k = u_k \dots u_2 u_1\}$ le langage des palindromes, n'est pas rationnel.

Exercice

Montrer que le langage $L_p = \{u_1 u_2 \dots u_k \mid u_1 u_2 \dots u_k = u_k \dots u_2 u_1\}$ le langage des palindromes, n'est pas rationnel.

Idée : considérer le mot $a^{N+1} b a^{N+1}$

Expressions régulières en pratique

La plupart des éditeurs de texte vous permettent de rechercher des expressions régulières :

- remplacer (`\n\s*= .*`)`\n` par `$1.\n`

Expressions régulières en pratique

Syntaxe :

- `.` → n'importe quel caractère (sauf `\n`)
- `\s` → n'importe quel espace / tab / etc
- `\w` → n'importe quelle lettre
- `[abfg ]` → un des caractères parmi "a" "b" "f" "g" et " ".
- `[^ab ]` → tout sauf un des caractères parmi "a" "b" " ".
- `*`, `+`, `?`, `|` → comme ce qu'on a vous

Expressions régulières en pratique

Remplacement :

- $\$0 \rightarrow$ tout
- $\$1 \rightarrow$ la première partie entre parenthèse
- $\$2 \rightarrow$ la deuxième, etc.